UNIVERSIDADE FEDERAL DA PARAÍBA
CENTRO DE CIÊNCIAS SOCIAIS APLICADAS
CURSO DE CIÊNCIA DE DADOS PARA NEGÓCIOS

RENATO SILVA DE ASSIS

SISTEMA INTEGRADO DE INTELIGÊNCIA PREDITIVA, CAUSAL E PRESCRITIVA PARA GESTÃO DE INADIMPLÊNCIA, EVASÃO E VALOR DISCENTE EM INSTITUIÇÕES DE ENSINO SUPERIOR PRIVADAS

João Pessoa — PB
Abril de 2026

Sumário

RESUMO 3
1 INTRODUÇÃO 4
2 OBJETIVOS 6
2.1 Objetivo Geral 6
2.2 Objetivos Específicos 6
3 REVISÃO DA LITERATURA 7
3.1 Teorias de Evasão e Permanência Estudantil 8
3.2 Credit Scoring, Behavioural Scoring e Inadimplência Educacional 9
3.3 CRM, Customer Lifetime Value e Machine Learning para Retenção Discente 10
3.4 Fronteira do Conhecimento 2023-2026 10
3.5 Síntese Comparativa da Literatura 11
3.6 Plataformas de Mercado 14
4 BASE DE DADOS 17
4.1 Sistema Moodle — LMS 17
4.2 ERP Prime — Histórico 2017-2025 18
4.3 ERP Sponte — A partir de 2026 18
4.4 Redes Sociais — Instagram Institucional 18
4.5 Textos de Atendimentos via WhatsApp 19
4.6 Sistema Prover — Eventos Institucionais 19
4.7 Dados Socioeconômicos Externos — INEP e IBGE 19
5 METODOLOGIA 21
5.1 Feature Engineering e Preparação de Dados 22
5.2 Modelagem Preditiva Supervisionada 22
5.3 Modelo de Sobrevivência de Cox 23
5.4 Segmentação — K-means e PCA 23
5.5 Inferência Causal — PSM e Uplift Modeling 23
5.6 Processamento de Linguagem Natural — BERTimbau 23
5.7 Customer Lifetime Value e Score Composto de Risco 24
5.8 Explicabilidade — SHAP 24
6 RESULTADOS ESPERADOS 25
7 CRONOGRAMA 26
8 CONSIDERAÇÕES PRELIMINARES 27
REFERÊNCIA 28

RESUMO

O ensino superior privado brasileiro enfrenta uma crise estrutural de retenção: taxa de evasão de 17,5% e inadimplência de 8,73% no primeiro semestre de 2025, ainda acima de todos os demais setores da economia (5,4% no crédito livre), chegando a 12,67% nas instituições de pequeno porte (INEP, 2025; SEMESP/Principia, 2025). A literatura reconhece que inadimplência e evasão são fenômenos multidimensionais com antecedentes financeiros, acadêmicos e comportamentais detectáveis com semanas de antecedência (Tinto, 1975; Saadia et al., 2022), mas nenhum estudo integrou, em uma única arquitetura operacional, dados financeiros, de LMS, de eventos, de atendimentos textuais e de redes sociais com as metodologias exigidas para transformar essa integração em inteligência gerencial acionável. Este projeto apresenta o Sistema Integrado de Inteligência Preditiva, Causal e Prescritiva para Gestão de Inadimplência, Evasão e Valor Discente em IES Privadas, que combina *gradient boosting* (XGBoost, LightGBM, CatBoost), modelos de sobrevivência de Cox, segmentação K-*means*, Propensity Score Matching, *uplift modeling*, NLP com BERTimbau em português brasileiro e explicabilidade por SHAP, respondendo às três lacunas centrais identificadas pela maior revisão sistemática da área: ausência de integração multifontes, de inferência causal e de prescrição gerencial estruturada (Quimiz-Moreira et al., 2025).

Palavras-chave: *machine learning*; inadimplência; evasão estudantil; IES privadas; *gradient boosting*; NLP; inferência causal; *uplift modeling*; aprendizado de máquina supervisionado.

1 INTRODUÇÃO

O ensino superior privado brasileiro constitui o maior sistema de educação superior com predominância privada do mundo em termos absolutos. Segundo o Censo da Educação Superior 2024 (INEP, 2025), o país atingiu a marca de 10 milhões de estudantes matriculados em cursos de graduação, dos quais 79,8%, aproximadamente 8 milhões de pessoas, frequentam instituições privadas. Esse crescimento expressivo, viabilizado historicamente por programas públicos como o FIES e o ProUni, ocorre em um contexto de retração progressiva do financiamento estudantil estatal, tornando as mensalidades pagas pelos próprios alunos a fonte quase exclusiva de receita operacional das 2.244 IES privadas existentes no país (INEP, 2025). O resultado é uma vulnerabilidade financeira estrutural que expõe essas instituições a dois fenômenos que se alimentam mutuamente e ameaçam sua sustentabilidade: a inadimplência e a evasão estudantil.

Os dados revelam a profundidade e a urgência do problema. A taxa de inadimplência no ensino superior privado, medida como o percentual de mensalidades com atrasos superiores a 90 dias, ficou em 8,73% no primeiro semestre de 2025, segundo a 17ª edição da Pesquisa de Inadimplência do Ensino Superior Privado (SEMESP/Principia, 2025), realizada com 293 instituições que representam 42,5% dos estudantes do país. Esse patamar, embora represente recuo de 1,9% em relação ao mesmo período de 2024, ainda supera amplamente o crédito livre (5,4%) e chega a 12,67% nas instituições de pequeno porte, as mais vulneráveis e menos capitalizadas para investir em soluções tecnológicas. A taxa de evasão, por sua vez, atingiu 17,5% no período 2023-2024, o maior índice desde 2010, alcançando 24,1% no ensino a distância contra 9,5% no presencial (INEP, 2025). Silva Filho et al. (2007) estimaram que a evasão representa um desperdício social, acadêmico e econômico de primeira ordem para o estudante, para a instituição e para a sociedade.

A gravidade do problema é amplificada por um vácuo regulatório que priva as IES privadas de ferramentas reativas eficazes. A jurisprudência consolidada do Superior Tribunal de Justiça (Súmula 694) proíbe o impedimento de participação em provas por inadimplência; a Lei de Diretrizes e Bases da Educação Nacional (Lei nº 9.394/1996) impede o bloqueio do acesso às aulas durante o semestre em curso; e o Código de Defesa do Consumidor (Lei nº 8.078/1990) veda qualquer constrangimento público ao devedor. Como registra Capelato, diretor executivo do SEMESP: a

educação é o único setor em que o consumidor pode deixar de pagar e continuar recebendo o serviço, criando um ciclo de inadimplência que muitas vezes culmina na evasão (SEMESP/Principia, 2025). O caminho eficaz, portanto, não é a reação, mas a prevenção: identificar o aluno em risco antes que inadimplir ou abandone, e agir com a intervenção adequada no momento certo.

A literatura acadêmica sobre predição de evasão e inadimplência em IES consolidou, ao longo de cinco décadas, uma base teórica e empírica robusta. Tinto (1975, 1993) formalizou o Modelo de Integração Estudantil; Bean e Metzner (1985) demonstraram que fatores financeiros e laborais são determinantes de evasão tão importantes quanto os institucionais; Saadia et al. (2022) realizaram o maior avanço nacional ao estudar 4.978 alunos de IES privada com regressão logística (acurácia de 80,7%, AUC de 0,84, Gini de 0,68); e Villar e De Andrade (2024) demonstraram que algoritmos de *gradient boosting* atingem AUC superior a 0,90. Na fronteira mais recente, Romero e Liao (2025) aplicaram Propensity Score Matching para estimar o efeito causal de bolsas sobre a retenção, e Athey, Keleher e Spiess (2025), em experimento de campo com 53.000 estudantes, provaram que o *targeting* por efeito causal estimado supera substancialmente o *targeting* preditivo puro, com redução de 25% no custo por resultado.

A revisão sistemática de Quimiz-Moreira et al. (2025), cobrindo 2.012 estudos pelo protocolo PRISMA (2012-2024), confirmou três lacunas estruturais persistentes: ausência de integração de múltiplas fontes de dados institucionais, inexistência de inferência causal e de *uplift modeling*, e ausência de camada prescritiva diferenciada por área funcional. Nenhuma das soluções de mercado disponíveis, nem as sofisticadas plataformas norte-americanas (Civitas Learning, EAB Navigate360) nem as fintechs brasileiras (Principia, Yolo Bank), integra inadimplência, evasão, LMS, NLP em português, causalidade, LTV individual e prescrição gerencial multiárea em um único sistema.

É diante desse cenário que este projeto propõe o Sistema Integrado de Inteligência Preditiva, Causal e Prescritiva para Gestão de Inadimplência, Evasão e Valor Discente em Instituições de Ensino Superior Privadas. A plataforma integra sete fontes de dados institucionais (ERP Prime, ERP Sponte, Moodle, Prover, atendimentos via WhatsApp, Instagram e dados externos INEP/IBGE) com uma esteira analítica de nove métodos complementares, gerando escores individuais de risco, estimativas de *Customer Lifetime Value* (LTV) e recomendações prescritas por

área gerencial, com conformidade LGPD nativa e arquitetura replicável para qualquer IES privada. O projeto encontra-se em fase de integração de dados: a integração com o Moodle já está concluída e em processo de validação; as demais fontes estão em fase de ETL.

2 OBJETIVOS

2.1 Objetivo Geral

Desenvolver e validar uma plataforma integrada de inteligência preditiva, causal e prescritiva capaz de identificar, classificar e priorizar riscos de inadimplência, evasão e perda de valor discente em instituições de ensino superior privadas, integrando dados financeiros, acadêmicos, comportamentais, relacionais e textuais de múltiplas fontes para gerar recomendações acionáveis às gestões financeira, comercial, de marketing e acadêmica, com conformidade LGPD e arquitetura replicável para qualquer IES privada.

2.2 Objetivos Específicos

OE1: Mapear, estruturar e integrar as sete fontes de dados da IES-piloto em repositório analítico único com conformidade LGPD (pseudonimização SHA-256, controle de acesso por perfil, logs de auditoria);
OE2: Construir e validar modelos preditivos de inadimplência e evasão por regressão logística (benchmark) e pelos algoritmos XGBoost, LightGBM e CatBoost (motor preditivo), com validação cruzada estratificada k-fold (k = 10) e otimização de hiperparâmetros via Optuna;
OE3: Desenvolver e validar um modelo de sobrevivência de Cox para estimar o timing do evento de inadimplência ou evasão, respondendo não apenas 'quem irá evadir' mas 'quando o evento ocorrerá';
OE4: Aplicar clustering K-means para segmentar a base discente em perfis de risco A a E, com determinação automática do número de clusters por silhouette score e PCA para redução de dimensionalidade;
OE5: Implementar Propensity Score Matching (PSM) e uplift modeling (T-Learner e Causal Forest) para estimar o efeito causal de políticas de bolsa, desconto e

intervenção sobre a probabilidade de permanência, identificando os alunos verdadeiramente persuasíveis;

OE6: Desenvolver e validar um pipeline de Processamento de Linguagem Natural com BERTimbau fine-tuned para análise de sentimento, classificação de intenção e extração de entidades em textos de fóruns Moodle, atendimentos via WhatsApp e comentários no Instagram;

OE7: Calcular o Customer Lifetime Value (LTV) discente individual ajustado pela probabilidade de sobrevivência do modelo de Cox, gerando o Customer Equity da base ativa como instrumento de priorização financeira dos esforços de retenção;

OE8: Implementar SHAP TreeExplainer para geração de explicações individuais e globais dos modelos preditivos, tornando cada alerta de risco compreensível e acionável para gestores sem expertise técnica em ML;

OE9: Desenvolver o protótipo da plataforma com dashboards em tempo real, alertas priorizados por Score Composto de Risco (SCR) e LTV, recomendações prescritas por área funcional e registro de trilha de auditoria;

OE10: Avaliar o impacto potencial da plataforma em indicadores financeiros (receita recuperável, redução de inadimplência), comerciais (taxa de rematrícula), de marketing (engajamento) e acadêmicos (progressão curricular, redução de evasão) da IES-piloto.

3 REVISÃO DA LITERATURA

Este capítulo apresenta o referencial teórico organizado em quatro blocos cronológicos e temáticos: (i) teorias clássicas de evasão e permanência estudantil; (ii) credit scoring, behavioural scoring e inadimplência educacional; (iii) CRM, Customer Lifetime Value e ML para retenção discente; e (iv) fronteira do conhecimento 2023-2026 em algoritmos de boosting, XAI, NLP e inferência causal. Ao final, são apresentados o Quadro 3.1 com síntese comparativa dos estudos acadêmicos e o Quadro 3.2 com análise comparativa das plataformas de mercado.

3.1 Teorias de Evasão e Permanência Estudantil

A compreensão científica da evasão tem origem em Durkheim (1897/1951), cujo conceito de integração social como determinante de comportamentos de retirada de um grupo forneceu a analogia central ao campo. Spady (1970, 1971) foi o primeiro a aplicar essa lógica ao ensino superior, propondo que a decisão de abandonar o curso resulta da insuficiente integração normativa e social do estudante. Tinto (1975), em 'Dropout from Higher Education: A Theoretical Synthesis of Recent Research' (Review of Educational Research, v. 45, n. 1, p. 89-125), formalizou o Modelo de Integração Estudantil, a teoria mais citada em toda a literatura de retenção por mais de cinquenta anos, postulando que a permanência depende do grau de integração acadêmica e social do aluno. Em 1987 e 1993, Tinto refinou o modelo em 'Leaving College' (University of Chicago Press), identificando três categorias de abandono: dificuldades acadêmicas, falta de propósito e incompatibilidade estudante-instituição. Revisões sistemáticas recentes confirmam que a teoria de Tinto permanece a principal referência no campo, utilizada como base em mais de 50% dos estudos de predição de evasão publicados entre 2012 e 2024 (Quimiz-Moreira et al., 2025). A limitação central do modelo, sua natureza qualitativa e a ausência de variáveis quantificáveis para modelagem preditiva, é precisamente o que o presente projeto supera ao operacionalizar as dimensões de Tinto como indicadores mensuráveis nos dados do ERP e do LMS.

Bean (1980), em 'Dropouts and Turnover: The Synthesis and Test of a Causal Model of Student Attrition' (Research in Higher Education, v. 12, n. 2, p. 155-187), adaptou a teoria de rotatividade organizacional ao contexto estudantil. Com dados de 1.171 calouros e análise de caminho (*path analysis*), demonstrou R^2 de 0,36 para mulheres e 0,27 para homens. Bean e Metzner (1985), em 'A Conceptual Model of Nontraditional Undergraduate Student Attrition' (Review of Educational Research, v. 55, n. 4, p. 485-540), expandiram o modelo para estudantes não-tradicionais, trabalhadores de tempo parcial e comutadores, demonstrando que fatores externos como dificuldades financeiras, carga de trabalho e obrigações familiares são tão ou mais determinantes que os fatores institucionais. Esse resultado é especialmente relevante para as IES privadas brasileiras, cujo perfil discente é predominantemente composto por trabalhadores-estudantes com restrições financeiras significativas.

No contexto brasileiro, Silva Filho et al. (2007), em 'A Evasão do Ensino Superior Brasileiro' (Cadernos de Pesquisa, v. 37, n. 132, p. 641-659), documentaram a escala do problema. Herling et al. (2013), em estudo publicado na Revista GUAL

(UFSC, v. 6, n. 2), confirmaram que a inadimplência em IES resulta da interação entre fatores pessoais, socioeconômicos, acadêmicos e institucionais, nunca de um único fator financeiro isolado. Andrade et al. (2008) descreveram o ciclo vicioso: a redução de caixa obriga a IES a reajustar mensalidades, o que converte alunos adimplentes em inadimplentes, que recorrem ao abandono silencioso antes do cancelamento formal.

3.2 Credit Scoring, Behavioural Scoring e Inadimplência Educacional

Rosenberg e Gleit (1994), em 'Quantitative Methods in Credit Management: A Survey' (Operations Research, v. 42, n. 4, p. 589-613), sistematizaram os principais métodos de gestão de crédito ao consumidor, estabelecendo análise discriminante e regressão logística como técnicas de referência. Thomas (2000), em 'A Survey of Credit and Behavioural Scoring: Forecasting Financial Risk of Lending to Consumers' (International Journal of Forecasting, v. 16, n. 2, p. 149-172), realizou a distinção seminal entre *credit scoring* de aprovação e *behavioural scoring*, este consistentemente superior por incorporar o histórico de comportamento do cliente ativo. Thomas identificou dois desenvolvimentos futuros centrais para o presente projeto: (1) incorporar condições econômicas externas (taxas de desemprego, PIB) ao modelo; e (2) migrar da estimativa de probabilidade de inadimplência para o *profit scoring*, precursor direto do Customer Lifetime Value.

Araújo e Carmona (2007) comprovaram que o *behavioural scoring* supera o *credit scoring* de aprovação: 88,5% vs. 80,3% de classificação correta na regressão logística, com o histórico de atrasos anteriores como o preditor mais relevante. Sobrinho (2007), em dissertação pela UFPE, realizou a primeira transposição ao setor educacional, obtendo 88,5% de acurácia com redes neurais em 245 alunos de escola básica em Recife. Saadia, Ferreira, Whately e Alvarez (2022), em 'Machine Learning na Previsão do Risco de Inadimplência de Alunos do Ensino Superior' (XLVI EnANPAD), realizaram o maior avanço nacional: 4.978 alunos de IES privada carioca (2017-2018), inadimplência de 20%, comparando regressão logística, árvore de decisão J48 e redes neurais MLP com validação k-fold (k = 10). A regressão logística apresentou a melhor acurácia (80,7%), AUC de 0,84 e Gini de 0,68. Os preditores mais relevantes foram débitos em semestres anteriores, variação no número de disciplinas cursadas, renda familiar de até dois salários-mínimos e vínculo

empregatício autônomo ou ausente. Os autores reconheceram explicitamente como lacunas: a impossibilidade de prever quando a inadimplência ocorrerá, a restrição a uma única IES e a ausência de dados de engajamento digital, espaço de contribuição que o presente projeto ocupa.

3.3 CRM, Customer Lifetime Value e Machine Learning para Retenção Discente

Dwyer (1989) formalizou o *Customer Lifetime Value* (CLV) como o valor presente dos benefícios esperados do cliente ao longo do relacionamento. Peppers e Rogers (2011) consolidaram o CRM como estratégia centrada na tríade *Get-Keep-Grow*, defendendo que a retenção é substancialmente mais lucrativa que a aquisição de novos clientes. Kumar (2018) avançou com a Customer Valuation Theory (CVT), propondo que portfólios de clientes devem ser geridos com os princípios de avaliação de portfólios financeiros. Pereira (2017), em dissertação de mestrado pela PUC-Rio, realizou a integração pioneira entre predição de evasão e cálculo de LTV discente no Brasil, com acurácia superior a 70% na identificação de evadidos e geração do *customer equity* da base ativa como instrumento de priorização de esforços de retenção, pela fórmula $LV_x = p_x \cdot \Sigma[M_t \cdot mgC_t / (1+r)^t]$. As limitações reconhecidas pelo próprio autor, impossibilidade de prever quando a evasão ocorrerá, restrição a uma única IES e ausência de dados de LMS, são precisamente as que o presente projeto endereça.

3.4 Fronteira do Conhecimento 2023-2026

Villar e De Andrade (2024), em estudo publicado na Discover Artificial Intelligence (Springer), identificaram 203 documentos sobre predição de *dropout* com ML e demonstraram que LightGBM e CatBoost com Optuna superam todos os métodos tradicionais, com AUC superior a 0,90. Rabelo e Zárate (2025) propuseram um ensemble por votação atingindo 89% de acurácia geral e 98,1% de identificação de evadidos. Marcolino et al. (2025), em artigo no Scientific Reports (Nature), demonstraram que CatBoost treinado em logs do Moodle de duas IES brasileiras, com balanceamento ADASYN e otimização NSGA-II, supera Random Forest e XGBoost em F1-score e recall para a classe de risco, validando o Moodle como fonte primária de predição em IES brasileiras.

Romero e Liao (2025), em 'Statistical and Machine Learning Models for Predicting University Dropout and Scholarship Impact' (PLOS ONE, v. 20, n. 6), foram os primeiros a aplicar Propensity Score Matching (PSM) para estimar o efeito causal de bolsas sobre o *dropout* em 4.424 registros de IES portuguesa, com XGBoost F1 = 0,904, confirmando que bolsas reduzem o *dropout* causalmente ($p < 0,01$). Athey, Keleher e Spiess (2025), em experimento de campo com 53.000 estudantes da City University of New York, provaram que o *targeting* por efeito causal individual, o *uplift modeling*, supera o *targeting* preditivo, com redução de 25% no custo por resultado, pois estudantes de probabilidade intermediária respondem mais às intervenções do que os de alto risco absoluto. Lundberg e Lee (2017) propuseram os SHAP values; Nagy e Molontay (2024) demonstraram que SHAP e LIME orientam intervenções personalizadas; Tiukhova et al. (2024) usaram SHAP para avaliar a estabilidade dos modelos ao longo do tempo. Souza, Nogueira e Lotufo (2020) publicaram o BERTimbau, modelo BERT pré-treinado para o português brasileiro com F-measure de 0,88 em análise de sentimento. Quimiz-Moreira et al. (2025), em revisão PRISMA de 2.012 estudos, confirmaram que integração multifontes, causalidade e prescrição gerencial permanecem as três lacunas centrais da área.

3.5 Síntese Comparativa da Literatura

Quadro 3.1 — Síntese comparativa dos estudos do referencial teórico e posicionamento do projeto

Autor/Ano	Objetivo	Base de Dados	Método	Melhor Resultado	Limitação Central	Diferencial do Projeto
Tinto (1975, 1993)	Explicar evasão por insuficiência de integração acadêmica e social	Literatura existente sobre atrito estudantil	Revisão teórica; analogia ao modelo de Durkheim (1897)	Modelo de Integração Estudantil, citado em >50% dos estudos da área	Sem variáveis quantificáveis nem dados transacionais	Operacionaliza as dimensões de Tinto como variáveis mensuráveis: CRA, engajamento LMS, participação em eventos
Bean & Metzner (1985)	Propor modelo de atrito para estudantes	Questionários, N = 1.171 calouros, EUA	Regressão múltipla e path analysis	R^2 = 0,36 (fem.) e 0,27 (masc.); fatores externos tão	Restrito ao contexto norte-americano;	Captura fatores externos via ERP (renda,

	não-tradicionais			determinantes quanto fatores institucionais	sem dados transacionais	vínculo empregatício) integrados ao modelo preditivo
Thomas (2000)	Mapear técnicas de credit e behavioural scoring	Revisão da literatura EUA e Reino Unido	Survey; RL, modelos de Markov, redes neurais	Distingue credit vs. behavioural scoring; aponta profit scoring como fronteira	Sem aplicação educacional; sem algoritmos de boosting modernos	Transpõe behavioural scoring ao aluno ativo com histórico financeiro e acadêmico, mais boosting
Araújo & Carmona (2007)	Avaliar credit scoring em instituição de microcrédito	245 clientes da Cred Cidadania (Recife-PE)	RL; credit vs. behavioural scoring; teste de Wald	Behavioural scoring logística: 88,5%; histórico de atrasos é o preditor mais relevante	Contexto microfinanceiro; sem aplicação educacional	Confirma histórico de atrasos como preditor-chave e adiciona Moodle, Prover e NLP
Sobrinho (2007)	Verificar viabilidade de credit scoring para inadimplência em escola básica	245 alunos de escola básica em Recife-PE	Análise discriminante, RL e redes neurais	Behavioural scoring com redes neurais: 88,5%; pioneiro na aplicação educacional	Base muito pequena (245 alunos); restrito ao ensino básico; sem dados de LMS ou eventos	Aplica à IES com >5.000 alunos, dados Moodle, NLP PT-BR e múltiplas fontes
Pereira (2017)	Estimar risco de evasão e calcular LTV para orientar retenção	IES privada do RJ; dados desde 2010; WEKA	RL, J48, KNN, SVM, Naive Bayes; k-fold k=10; LTV = px·S[Mx·mgC/(1+r)t]	Acurácia >70%; LTV individual calculado; customer equity da base ativa, pioneiro no Brasil	Não informa QUANDO a evasão ocorre; 1 IES; sem Moodle; sem causalidade	Supera com Cox (timing), Moodle, Prover, NLP, PSM, Uplift e arquitetura multi-IES
Saadia et al. (2022)	Propor credit scoring com ML para IES privada no Brasil	4.978 alunos de IES privada do RJ (2017-2018); inadimplência 20%	RL, árvore J48, MLP; k-fold k=10; variáveis financeiras, acadêmicas e sociodemográficas	RL: acurácia 80,7%, AUC 0,84, Gini 0,68; preditores-chave: débitos anteriores, variação de disciplinas, renda	Não prevê timing; sem LMS, eventos, NLP; 1 IES; sem causalidade; sem prescrição gerencial	Inclui Cox, Moodle, Prover, BERTimbau, PSM, Uplift, LTV e prescrição por área funcional
Villar & De	Comparar XGBoost, CatBoost,	Dataset UCI - IES portuguesa	DT, SVM, RF, GB, XGBoost, CatBoost,	LightGBM e CatBoost + Optuna: AUC > 0,90;	Dataset único; sem NLP, eventos	Aplica os mesmos algoritmos

Andrade (2024)	LightGBM vs. algoritmos tradicionais	(4.424 registros)	LightGBM; SMOTE; Optuna; 15 artigos mais citados revisados	superam todos os métodos tradicionais	ou financeiro transacional; sem causalidade	com dados multifontes brasileiros, mais Cox, NLP e Uplift
Rabelo & Zárate (2025)	Melhorar predição de evasão com ensemble (RL + RNA + árvore)	IES brasileira; múltiplos cursos e anos	Ensemble por votação; knowledge discovery process	89% de acurácia geral; 98,1% de identificação de evadidos (recall)	1 fonte de dados; sem NLP; sem causalidade; sem prescrição gerencial	Integra múltiplas fontes, causalidade, LTV e recomendações gerenciais por área
Romero & Liao (2025)	Predizer dropout e estimar efeito causal de bolsas via PSM	4.424 registros de IES portuguesa pública (UCI)	Lasso, GAM, RF, XGBoost; PSM para efeito causal de bolsas	XGBoost F1 = 0,904; bolsas reduzem dropout causalmente ($p<0,01$); notas do 2º sem. são o preditor mais importante	Dados acadêmicos apenas; 1 IES; sem LMS, NLP, prescrição ou LTV	Aplica PSM em IES privada brasileira, acrescenta Uplift, LTV, NLP e prescrição multiárea
Marcolino et al. (2025)	Predição de dropout com CatBoost em logs do Moodle (Scientific Reports)	Moodle de UFSC e UFPel (IES brasileiras públicas); desbalanceado	CatBoost + ADASYN + NSGA-II; k-fold estratificado	CatBoost+ADASYN+NSGA-II supera RF e XGBoost; Moodle validado como fonte primária no Brasil	Dataset pequeno; IES públicas; sem ERP, NLP, eventos ou causalidade	Integra Moodle com ERP, Prover e BERTimbau em escore unificado com prescrição em IES privada
Athey, Keleher & Spiess (2025)	Comparar targeting preditivo vs. causal para nudge de auxílio financeiro	City University of New York, experimento de campo com 53.000 alunos	Experimento de campo; causal forest; S-Learner; T-Learner	Targeting causal supera preditivo; probabilidade intermediária responde mais; custo/resultado melhora 25%	Contexto de auxílio financeiro; sem integração de dados acadêmicos, LMS ou financeiros transacionais	Incorpora uplift modeling para targeting de intervenções em IES privada brasileira
Quimiz-Moreira et al. (2025)	Revisão PRISMA de 2.012 estudos de ML para dropout (2012-2024)	2.012 publicações indexadas no Scopus e WoS (2012-2024)	PRISMA; análise bibliométrica e de conteúdo; 83 modelos ML identificados	520 fatores; 83 modelos ML; SHAP/LIME dominam XAI; boosting em crescimento acelerado	Confirma 3 lacunas: integração multifontes, causalidade e prescrição gerencial ausentes na área	Responde às 3 lacunas centrais identificadas na maior revisão sistemática da área em 2025

Fonte: elaborado pelo autor (2026). RL = Regressão Logística; PSM = Propensity Score Matching; LTV = Lifetime Value; NLP = Processamento de Linguagem Natural; LMS = Learning Management System.

3.6 Plataformas de Mercado

O mapeamento das soluções tecnológicas de mercado complementa o referencial teórico, demonstrando que o problema da inadimplência e evasão em IES possui escala suficiente para justificar investimentos tecnológicos substanciais e que as soluções existentes, embora evoluídas em dimensões específicas, apresentam lacunas estruturais que o presente projeto se propõe a superar. São analisadas dez plataformas, seis internacionais e quatro nacionais, selecionadas por relevância de mercado, adoção, sofisticação metodológica e resultados documentados.

A Civitas Learning (EUA, 2011) unifica dados de SIS, LMS e CRM em *analytics* de student success institution-specific, com modelos de *Persistence Prediction* e *Completion Prediction* atualizados diariamente e técnica própria de avaliação de eficácia denominada PPSM (Prediction-based Propensity Score Matching). Resultados documentados: +14,5 pontos percentuais de retenção de calouros em universidade pública da Flórida; +18% na taxa de formação em 4 anos; eliminação de lacunas de equidade por raça, etnia e renda (Student Success Impact Report, 2025). O EAB Navigate360 (EUA, 2011), presente em 850+ instituições com 10 milhões de estudantes, deploia mais de 200 modelos preditivos customizados. Como resultados dessas iniciativas, pode-se citar, US$5,2 milhões em receita adicional recuperada na Universidade de Albany (SUNY); +12% de retenção em 4 anos na Universidade do Alabama do Sul; retenção de 65 alunos adicionais por semestre na VCU com US$346.000 em receita recuperada (EAB Case Study Compendium, 2024).

No mercado nacional, a Principia (Brasil, 2022) assume toda a gestão de contas a receber da IES (produto Receita Garantida), utilizando IA proprietária e Open Finance para previsão de inadimplência. Resultados: R$170 milhões em faturamento anualizado no 1T 2025; R$190 milhões captados (Série A, liderada pela Valor Capital); 600+ IES clientes; 500.000+ alunos; certificação B Corp (Brazil Journal, 2025). O Yolo Bank (Brasil, 2023) combina IA proprietária com Open Finance para prever inadimplência com 10 dias de antecedência ao vencimento e liberar descontos automáticos calibrados por aluno, com 76 IES parceiras e 700.000 estudantes em

2024 (Startups.com.br, 2024). Nenhuma das plataformas analisadas integra inadimplência, evasão, LMS, NLP em português, causalidade, LTV individual e prescrição gerencial multiárea em um único sistema, espaço de contribuição que o presente projeto ocupa.

Quadro 3.2 — Análise comparativa das plataformas de mercado e posicionamento do projeto

Plataforma / País / Ano	Foco Principal	Metodologia	Resultado Documentado	Limitação vs. Projeto
Civitas Learning (EUA, 2011)	Student success analytics; ML institution-specific; PPSM	ML supervisionado; PPSM; analytics adaptável; SIS+LMS+CRM	+14,5 p.p. retenção; +18% formação em 4 anos; eliminação equity gaps	Sem inadimplência financeira; sem NLP PT-BR; sem LTV; sem LGPD
EAB Navigate360 (EUA, 2011)	CRM de student success, 850+ IES, 10M alunos	200+ modelos preditivos customizados; IA generativa; Smart Network; early alerts	+12% retenção em 4 anos; US$5,2M receita recuperada (Albany/SUNY)	Sem inadimplência; sem PSM+Uplift; sem NLP PT-BR; sem LTV; sem LGPD
Element451 (EUA, 2013)	CRM AI-first; admissão; retenção; alumni, 250+ IES	Bolt Agents autônomos; IA preditiva; automação multicanal; parceria AWS	+10h/semana de capacidade por usuário; maior taxa de conversão de admissão	Foco em admissão; sem inadimplência; sem NLP PT-BR; sem causalidade; sem LTV
Salesforce Education Cloud (EUA)	CRM enterprise; admissão; student success; alumni; fundraising	Education Data Architecture (EDA); Agentforce; Data Cloud; Marketing Cloud	ROI: +5,5% enrollment; +10% fundraising (Forrester Consulting)	Alto custo; add-ons obrigatórios; sem inadimplência específica; sem NLP PT-BR
Jenzabar Retention (EUA, 1969)	Retenção integrada ao SIS Jenzabar;	Success markers configuráveis; workflows de intervenção; dashboards de risco; chatbot IA	Alertas precoces integrados ao SIS; gestão	Restrito ao ecossistema Jenzabar; sem ML sofisticado; sem NLP; sem

	early-alert, 1.400+ IES		centralizada de atendimento	LTV; sem causalidade
IntelliBoard (EUA, 2013)	Analytics de LMS/Moodle; identificação de alunos em risco	ML sobre logs de LMS; alertas automáticos; dashboards personalizados	Melhoras reportadas em retenção por identificação precoce via engajamento digital	Exclusivamente LMS; sem inadimplência; sem NLP; sem causalidade; sem LTV
Principia (Brasil, 2022)	Receita Garantida + ERP acadêmico, 600+ IES, 500K+ alunos	IA proprietária + Open Finance; gestão de contas a receber; scoring de inadimplência	R$170M faturamento anual (1T2025); R$190M captados; 600+ IES; B Corp certificada	Exclusivamente financeiro; sem Moodle; sem NLP PT-BR; sem causalidade; sem LTV individual
Yolo Bank (Brasil, 2023)	IA + Open Finance; previsão 10 dias antes do vencimento, 76 IES	IA proprietária + Open Finance; desconto automático calibrado por aluno	76 IES parceiras; 700K estudantes; R$3M captados; selecionado Impulsiona Startups Serasa	Exclusivamente financeiro; sem acadêmico; sem NLP; sem clustering; sem LTV; sem prescrição
Datarisk (Brasil)	Churn educacional e modelagem de risco para escolas privadas	Modelos preditivos de churn; análise comportamental; sinais semanas antes da saída	Sinais de evasão identificados semanas antes da decisão; redução de transferências	Foco no ensino básico; sem dados LMS; sem NLP PT-BR; sem causalidade formal
Presente Projeto (Brasil, 2026)	**Plataforma integrada preditiva, causal e prescritiva para qualquer IES privada**	**XGBoost+LightGBM+CatBoost+Cox+K-means+PSM+Uplift+BERTimbau+SHAP; 7 fontes; LGPD nativa**	**(Esperado) Escore A-E; timing via Cox; LTV individual; CATE individual; prescrição multiárea**	**INTEGRA TUDO: inadimplência + evasão + LMS + NLP PT-BR + causalidade + LTV + LGPD + multi-IES**

Fonte: elaborado pelo autor com base em dados públicos das plataformas (2025-2026).

4 BASE DE DADOS

Este capítulo descreve as fontes de dados, os indicadores e métricas derivados de cada fonte, a justificativa da literatura para cada variável e o estado atual de integração. A integração via API já está em andamento: a integração com o Moodle está concluída e em fase de validação; as demais fontes encontram-se em fase de ETL e integração. Ao final, o Quadro 4.1 consolida todas as variáveis utilizadas pela literatura e pelo projeto.

4.1 Sistema Moodle — LMS

O Moodle (Modular Object-Oriented Dynamic Learning Environment) é o LMS de código aberto mais adotado no mundo, com mais de 400 milhões de usuários em 243 países. Marcolino et al. (2025) validaram os logs do Moodle como fonte primária de predição de risco em IES brasileiras; Macfadyen e Dawson (2010) demonstraram que frequência de login, atividades enviadas e mensagens postadas nos fóruns são preditores significativos de reprovação (r = 0,49 com nota final); Siemens e Baker (2012) e Siemens (2013) fundamentaram a Learning Analytics como campo que usa dados de LMS para apoio à decisão educacional. A integração com o Moodle via API já está concluída e em fase de validação.

Do Moodle, o projeto extrai dois grupos de variáveis. O primeiro, dados estruturados, inclui: frequência e regularidade temporal de login; número e *timestamp* de submissões de atividades (tarefas, questionários, fóruns, wikis, SCORM); notas por atividade e por disciplina; progresso curricular; acesso a recursos; Cognitive Depth e Social Breadth (indicadores nativos do Moodle Analytics). O segundo grupo, dados não estruturados, inclui textos integrais de posts em fóruns de discussão, mensagens em chat interno e feedbacks escritos, processados pelo módulo BERTimbau. A variável derivada central é o Slope de Engajamento Digital (SED), que mede a tendência temporal do engajamento nas últimas semanas por regressão linear de acessos sobre tempo, sendo que uma queda consistente antecede o abandono

silencioso com semanas de antecedência (Wang e Mousavi, 2022; Marcolino et al., 2025).

4.2 ERP Prime — Histórico 2017-2025

O ERP Prime foi utilizado pela IES-piloto até o final de 2025 e disponibilizou o histórico financeiro e acadêmico completo de 2017 a 2024 em formato de planilhas Excel. Esse conjunto representa a série temporal mais longa do projeto, essencial para os modelos de sobrevivência de Cox (Cox, 1972), que exigem dados longitudinais com registro de tempo até o evento. Do Prime, são extraídas variáveis financeiras (valor da mensalidade, valor pago, percentual de desconto, data de vencimento e data de pagamento, número acumulado de débitos, renegociações, tipo de financiamento) e acadêmicas (curso, turno, modalidade, IRA por semestre, número de disciplinas cursadas, aprovadas, reprovadas e trancadas, datas de ingresso e saída). Saadia et al. (2022) e Pereira (2017) confirmaram que histórico de débitos, variação do IRA (CRA) e tipo de financiamento são os preditores mais relevantes da inadimplência e evasão em IES privadas brasileiras.

4.3 ERP Sponte — A partir de 2026

O Sponte é o ERP acadêmico-financeiro adotado pela IES-piloto a partir de janeiro de 2026, em substituição ao Prime. Diferentemente do Prime, o Sponte oferece API REST para extração de dados em tempo real, permitindo ao projeto atualizar os modelos preditivos de forma contínua via webhooks para os módulos de: situação financeira do aluno (atualizado diariamente), lançamentos de notas e frequência (em tempo real), registro de matrículas e rematrículas, e log de atendimentos internos. A integração está em fase de ETL.

4.4 Redes Sociais — Instagram Institucional

O perfil oficial da faculdade no Instagram é uma fonte complementar de dados relacionais e de sentimento. A extração é realizada via Instagram Graph API (para perfis business), coletando comentários em publicações institucionais, menções ao

perfil e interações por tipo de publicação. O processamento utiliza BERTimbau *fine-tuned* para análise de sentimento e classificação de intenção. A identificação individual de alunos nas redes sociais só é possível mediante consentimento expresso, conforme Art. 7°, I, da LGPD. A integração está em fase de ETL.

4.5 Textos de Atendimentos via WhatsApp

A IES-piloto possui um histórico de conversas de atendimento via WhatsApp realizadas pelos setores comercial e de secretaria acadêmica. Esse corpus textual representa um dado extremamente rico e até agora inexplorado: os alunos revelam, no contexto de atendimentos, informações sobre intenção de cancelamento, dificuldades financeiras e necessidade de negociação, frequentemente antes de qualquer solicitação oficial. O processamento segue o pipeline NLP padrão: tokenização com *wordpiece* do BERTimbau, extração de entidades nomeadas, classificação de intenção (rematrícula, cancelamento, negociação, reclamação) e análise de sentimento por turno da conversa. Essa é uma contribuição original do projeto: nenhum estudo anterior utilizou textos de atendimentos institucionais via WhatsApp como fonte para predição de inadimplência ou evasão em IES privadas brasileiras. A integração está em fase de ETL.

4.6 Sistema Prover — Eventos Institucionais

O Prover é o sistema utilizado pela IES para gestão de inscrições e check-in em eventos institucionais. O banco de dados do Prover registra data e nome do evento, categoria, número de inscritos, número de presentes via check-in e identificadores dos alunos participantes. A participação em eventos é um proxy direto do nível de vínculo do aluno com a instituição, dimensão identificada por Bean e Metzner (1985) e Tinto (1993) como determinante da permanência especialmente para trabalhadores-estudantes. O projeto constrói, a partir do Prover, o Indicador de Pertencimento Institucional (IPI-e): $IPI\text{-}e_i = \log(1 + eventos_comparecidos_semestre_i)$. Essa é uma proposta original sem precedente identificado na literatura de IES privadas. A integração está em fase de ETL.

4.7 Dados Socioeconômicos Externos — INEP e IBGE

O projeto incorpora dados externos como covariáveis contextuais dos modelos preditivos. Do INEP, são extraídos microdados públicos anuais do Censo da Educação Superior. Do IBGE, são incorporados indicadores da PNAD Contínua: taxa de desemprego estadual, renda per capita e índice de escolaridade superior por município. Thomas (2000) foi o primeiro a propor a incorporação de condições econômicas externas como preditores sistêmicos de inadimplência. Saadia et al. (2022) identificaram renda familiar e vínculo empregatício como os preditores sociodemográficos mais relevantes em IES privada brasileira.

Quadro 4.1 — Variáveis utilizadas pela literatura e pelo projeto por dimensão analítica

Variável / Indicador	Dimensão	Fonte no Projeto	Estudos que Utilizaram	Status
Histórico de débitos anteriores	Financeira	ERP Prime/Sponte	Saadia et al. (2022); Araújo & Carmona (2007); Pereira (2017)	Confirmado
Valor e variação da mensalidade	Financeira	ERP Prime/Sponte	Saadia et al. (2022); Herling et al. (2013)	Confirmado
Tipo de financiamento (FIES, ProUni, bolsa)	Financeira	ERP Prime/Sponte	Romero & Liao (2025); Saadia et al. (2022)	Confirmado
Percentual de desconto/bolsa aplicado	Financeira	ERP Prime/Sponte	Romero & Liao (2025); Pereira (2017)	Confirmado
Número de renegociações/parcelamentos	Financeira	ERP Prime/Sponte	Araújo & Carmona (2007); Thomas (2000)	Confirmado
Score de Vulnerabilidade Financeira (SVF)	Financeira derivada	ERP Prime/Sponte	Proposta original com base em Saadia et al. (2022)	Proposta original
CRA — Coeficiente Rendimento Acadêmico	Acadêmica	ERP Prime/Sponte	Saadia et al. (2022); Pereira (2017); Villar & De Andrade (2024)	Confirmado
Variação semestral do CRA (ΔCRA)	Acadêmica derivada	ERP Prime/Sponte	Proposta derivada de Saadia et al. (2022)	Proposta original
Nº de disciplinas cursadas, aprovadas, reprovadas, trancadas	Acadêmica	ERP Prime/Sponte	Saadia et al. (2022); Romero & Liao (2025); Villar & De Andrade (2024)	Confirmado
Turno, modalidade, curso	Acadêmica	ERP Prime/Sponte	Rabelo & Zárate (2025); Marcolino et al. (2025)	Confirmado
Semestres cursados (tempo até o evento)	Acadêmica	ERP Prime/Sponte	Pereira (2017); Cox (1972), para modelo de sobrevivência	Confirmado
Frequência e regularidade de login no Moodle	Engajamento digital	Moodle LMS (API integrado)	Marcolino et al. (2025); Macfadyen & Dawson (2010)	Integrado e em validação

Número de atividades submetidas	Engajamento digital	Moodle LMS (API integrado)	Marcolino et al. (2025); Macfadyen & Dawson (2010)	Integrado e em validação
Participação em fóruns (nº de posts)	Engajamento digital	Moodle LMS (API integrado)	Marcolino et al. (2025); Siemens & Baker (2012)	Integrado e em validação
Cognitive Depth e Social Breadth	Engajamento digital	Moodle LMS (API integrado)	Moodle Analytics (2024); Siemens (2013)	Integrado e em validação
Slope de Engajamento Digital (SED)	Engajamento digital derivada	Moodle LMS (API integrado)	Wang & Mousavi (2022); proposta derivada do projeto	Proposta original
Texto de fóruns Moodle (NLP: sentimento, intenção, NER)	Engajamento textual	Moodle LMS (API integrado)	BERTimbau (Souza et al., 2020); proposta original para IES privada brasileira	Proposta original
Renda familiar estimada	Sociodemográfica	ERP Prime/Sponte + IBGE/PNAD	Saadia et al. (2022); Bean & Metzner (1985); Pereira (2017)	Confirmado
Vínculo empregatício do aluno	Sociodemográfica	ERP Prime/Sponte	Saadia et al. (2022); Bean & Metzner (1985)	Confirmado
Idade, gênero, estado civil	Sociodemográfica	ERP Prime/Sponte	Quimiz-Moreira et al. (2025): 520 fatores mapeados	Confirmado
Taxa de desemprego municipal/estadual	Macroeconômica	IBGE/PNAD Contínua	Thomas (2000); Saadia et al. (2022)	Confirmado
Participação em eventos institucionais (IPI-e)	Pertencimento/social	Prover (em fase ETL)	Tinto (1993); Bean & Metzner (1985); proposta original via Prover	Proposta original — Prover em integração
Texto de atendimentos WhatsApp (NLP: intenção, sentimento)	Textual/relacional	Atendimentos WhatsApp (em fase ETL)	BERTimbau (Souza et al., 2020); proposta completamente original	Proposta original — em integração
Comentários e sentimento no Instagram institucional	Percepção/reputação	Instagram Graph API (em fase ETL)	BERTimbau (Souza et al., 2020); proposta original do projeto	Proposta original — em integração
LTV discente individual (Customer Lifetime Value)	Valor econômico	Calculado pelo modelo	Pereira (2017); Dwyer (1989); Kumar (2018)	Confirmado com extensão via Cox
CATE individual via Uplift (T-Learner / Causal Forest)	Causalidade	Calculado pelo modelo	Athey, Keleher & Spiess (2025); aplicação original em IES privada brasileira	Proposta original

Fonte: elaborado pelo autor (2026). Itens marcados como 'Proposta original' não foram utilizados em combinação equivalente na literatura de IES privadas brasileiras.

5 METODOLOGIA

O projeto adota delineamento de pesquisa aplicada de natureza quantitativa e caráter longitudinal, com dados de 2017 a 2026. A estratégia metodológica segue o *framework* descritivo-preditivo-prescritivo (Provost e Fawcett, 2013) organizado em

seis camadas encadeadas. Todos os modelos são validados por k-fold estratificado (k = 10) com validação temporal para evitar *data leakage*. A preparação de dados segue o protocolo CRISP-DM (Wirth e Hipp, 2000).

5.1 Feature Engineering e Preparação de Dados

A imputação múltipla por MICE (*Multivariate Imputation by Chained Equations*; van Buuren e Groothuis-Oudshoorn, 2011) é aplicada para dados ausentes (missingness < 30%), com indicadores binários de ausência para variáveis com missingness ≥ 30%, preservando o sinal informativo da ausência em variáveis do Moodle. A detecção de anomalias utiliza Isolation Forest (Liu, Ting e Zhou, 2008). As variáveis derivadas centrais são:

$$SED_i = \hat{\beta}_1 \text{ da regressão linear: } acessos_i \sim tempo\ (semanas\ t_1..t_n) \quad (5.1)$$

Slope de Engajamento Digital — queda sistemática indica abandono silencioso iminente

$$SVF_i = (Débitos_acumulados_i / Mensalidade_i) \times 100 \quad (5.2)$$

Score de Vulnerabilidade Financeira — proporção do valor total em atraso

$$\Delta CRA_i = CRA_\{i,t\} - CRA_\{i,t-1\} \quad (5.3)$$

Variação semestral do Coeficiente de Rendimento Acadêmico

5.2 Modelagem Preditiva Supervisionada

A regressão logística (Hosmer e Lemeshow, 2000) é o modelo *benchmark* interpretável, cada coeficiente β_j produz um *odds ratio* comunicável à gestão (Saadia et al., 2022):

$$P(Y_i = 1 \mid X_i) = 1 / [\ 1 + \exp(-\beta_0 - \Sigma_j \beta_j x_{ji})\ ] \quad (5.4)$$

Modelo logístico de inadimplência/evasão — benchmark interpretável

Os motores preditivos de alta performance são XGBoost (Chen e Guestrin, 2016), LightGBM (Ke et al., 2017) e CatBoost (Prokhorenkova et al., 2018), com

otimização via Optuna e balanceamento ADASYN (He et al., 2008). Critérios de aceitação: AUC > 0,80; F1 > 0,70; Recall > 0,75 para a classe de risco. Villar e De Andrade (2024) demonstraram AUC > 0,90 com LightGBM e CatBoost + Optuna. A seleção de modelo segue a estratégia *champion-challenger* (Thomas, 2000): o modelo com maior AUC em validação torna-se o modelo de produção, enquanto o segundo melhor é reavaliado a cada semestre.

5.3 Modelo de Sobrevivência de Cox

O Modelo de Regressão de Cox (Cox, 1972) responde quando o evento ocorrerá, a principal lacuna apontada por Saadia et al. (2022) e Pereira (2017). Critério de aceitação: C-statistic (concordância) > 0,70; teste de proporcionalidade de riscos por resíduos de Schoenfeld (p > 0,05; Grambsch e Therneau, 1994).

$$h(t \mid X_i) = h_0(t) \cdot \exp(\beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi}) \tag{5.5}$$

$h_0(t)$ = risco basal; $\exp(\beta_j)$ = hazard ratio da variável j

$$\hat{S}_i(t) = \exp[-H_0(t) \cdot \exp(X_i\beta)] \tag{5.6}$$

Curva de sobrevivência individual — probabilidade de permanência até o tempo t

5.4 Segmentação — K-means e PCA

$$WCSS = \Sigma_k \Sigma_{i \in C_k} \| x_i - \mu_k \|^2 \tag{5.7}$$

K-means: minimização da soma de quadrados intragrupo (MacQueen, 1967)

$$Silhouette(i) = [\, b(i) - a(i) \,] / \max\{ a(i), b(i) \} \tag{5.8}$$

a(i) = distância média intra-cluster; b(i) = distância média ao cluster mais próximo. Critério: Silhouette > 0,50

5.5 Inferência Causal — PSM e Uplift Modeling

$$e(X_i) = P(D_i = 1 \mid X_i) \;\rightarrow\; ATT = E[\, Y_i(1) - Y_i(0) \mid D_i = 1 \,] \tag{5.9}$$

PSM: propensity score e Average Treatment Effect on the Treated (Rosenbaum & Rubin, 1983)

$$\hat{\tau}(X_i) = \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) \tag{5.10}$$

T-Learner: CATE individual — Conditional Average Treatment Effect (Künzel et al., 2019)

5.6 Processamento de Linguagem Natural — BERTimbau

$$Attention(Q, K, V) = softmax(QK^T / \sqrt{d_k}) \cdot V \quad (5.11)$$

Mecanismo de atenção multi-cabeça do Transformer (Vaswani et al., 2017); base do BERT

$$P(classe \mid texto) = softmax(W \cdot h_{[CLS]} + b) \quad (5.12)$$

Classificador fine-tuned sobre representação BERTimbau do token [CLS] (Souza, Nogueira & Lotufo, 2020)

5.7 Customer Lifetime Value e Score Composto de Risco

$$LTV_i = \Sigma_t [\hat{S}_i(t) \cdot M_t \cdot mgC_t / (1 + r)^t] \quad (5.13)$$

LTV ajustado pela curva de sobrevivência Cox; extensão de Pereira (2017) e Dwyer (1989)

$$SCR_i = w_1\hat{P}_{inad} + w_2\hat{P}_{evasão} + w_3(1 - \hat{S}_i(6)) + w_4(-SNLP_i) + w_5(1 - IPI\text{-}e_i) \quad (5.14)$$

Score Composto de Risco; $\Sigma w_k = 1$; pesos calibrados por importância SHAP média; normalizado para [0,1]

5.8 Explicabilidade — SHAP

$$f(X_i) = E[f(X)] + \Sigma_j \varphi_j(i) \quad (5.15)$$

Decomposição aditiva SHAP: a predição é a média mais contribuições individuais de cada feature (Lundberg & Lee, 2017)

Quadro 5.1 — Síntese metodológica, critérios de validação e referências

Método	Referência Seminal	Referência Recente de Aplicação	Critério Mínimo de Aceitação
Regressão Logística (benchmark)	Hosmer & Lemeshow (2000); Thomas (2000)	Saadia et al. (2022): 80,7% acurácia, AUC 0,84	AUC > 0,75; Gini > 0,50; Hosmer-Lemeshow p > 0,05
XGBoost / LightGBM / CatBoost + Optuna	Chen & Guestrin (2016); Ke et al. (2017); Prokhorenkova et al. (2018)	Villar & De Andrade (2024): AUC > 0,90	AUC > 0,80; F1 classe risco > 0,70; Recall > 0,75
ADASYN (balanceamento)	He et al. (2008)	Marcolino et al. (2025): CatBoost + ADASYN em IES brasileiras	SMD pós-balanceamento < 0,20
Cox Proportional Hazards (timing)	Cox (1972); Thomas (2000)	Romero & Liao (2025): PSM + XGBoost em IES portuguesa	Schoenfeld p > 0,05; C-statistic > 0,70

K-means + PCA (segmentação)	MacQueen (1967); Jolliffe (2002)	Marcolino et al. (2025)	Silhouette > 0,50; Davies-Bouldin < 1,0
PSM (Propensity Score Matching)	Rosenbaum & Rubin (1983)	Romero & Liao (2025): efeito causal de bolsas confirmado (p < 0,01)	SMD pós-matching < 0,10
Uplift Modeling (T-Learner / Causal Forest)	Künzel et al. (2019); Athey & Imbens (2016)	Athey, Keleher & Spiess (2025): custo/resultado melhora 25%	Uplift curve > AUC preditivo baseline
BERTimbau NLP PT-BR	Devlin et al. (2019); Souza, Nogueira & Lotufo (2020)	BERTimbau: F-measure 0,88 sentimento; 0,89 hate speech em PT-BR	F1-macro > 0,75; validação temporal
SHAP TreeExplainer	Lundberg & Lee (2017); Shapley (1953)	Nagy & Molontay (2024); Tiukhova et al. (2024)	Consistência SHAP-LIME > 0,80 nas top-5 features

Fonte: elaborado pelo autor (2026). EPV ≥ 10 (eventos por preditor) verificado em todos os modelos supervisionados.

6 RESULTADOS ESPERADOS

Com base nos resultados obtidos pelos estudos de referência e pelas plataformas de mercado, o projeto prevê os seguintes resultados para a IES-piloto ao final do projeto:

Financeiros: redução de pelo menos 3 pontos percentuais na taxa de inadimplência no primeiro ano de operação, correspondendo a aproximadamente R$480 mil adicionais de receita mensal para uma IES com 2.000 alunos e mensalidade média de R$800, alinhado com os resultados documentados pela Principia (2025) e pela Civitas Learning (2025).

Retenção: aumento de 5 a 10 pontos percentuais na taxa de rematrícula semestral dos alunos dos clusters C e D, mediante intervenção proativa antes do encerramento do semestre, comparável ao +12% de retenção em 4 anos documentado pelo EAB Navigate360 (2024).

Comerciais: redução do custo de retenção por aluno salvo, com concentração de esforços nos persuasíveis identificados pelo uplift modeling. Athey, Keleher e Spiess (2025) demonstraram que esse tipo de targeting reduz o custo por resultado em 25% em relação ao targeting por risco absoluto.

Acadêmicos: identificação precoce de alunos com risco de reprovação e trancamento com pelo menos 4 semanas de antecedência, possibilitada pelo Slope de Engajamento Digital (SED) do Moodle, conforme Wang e Mousavi (2022) e Marcolino et al. (2025).

Modelos preditivos: AUC > 0,80 para regressão logística (benchmark) e AUC > 0,90 para os algoritmos de boosting, compatível com os resultados de Villar e De Andrade (2024) e Rabelo e Zárate (2025) em datasets similares.

NLP: F1-macro > 0,75 no BERTimbau fine-tuned para classificação de intenção de cancelamento nos textos de atendimentos e fóruns Moodle, com pelo menos 30 dias de antecedência ao cancelamento formal, proposta original sem comparável na literatura.

Científicos: submissão de artigo em periódico classificado no Qualis-CAPES como A2 ou superior, com contribuição inédita à literatura nacional e internacional pela integração de PSM, uplift modeling e NLP em português para retenção em IES privadas brasileiras.

Replicabilidade: arquitetura modular validada para implementação em pelo menos uma segunda IES privada ao final do projeto, demonstrando a escalabilidade do framework para o universo de 2.244 IES privadas no Brasil (INEP, 2025).

7 CRONOGRAMA

Quadro 7.1 — Cronograma de atividades (Fevereiro de 2026 – Agosto de 2026)

Atividade	Fev/26	Mar/26	Abr/26	Mai/26	Jun/26	Jul/26	Ago/26
1. **Revisão da literatura**	x	x					
2. **Integração e validação dos dados do Moodle**			X	x			
3. **ETL e integração do ERP Sponte via API**			x	x			
4. **Migração e limpeza do histórico ERP Prime**			x	x			
5. **ETL dos atendimentos via WhatsApp (pipeline NLP)**			X	x	x		
6. **ETL Instagram e Prover (eventos)**			X	x	x		
7. **Análise exploratória e feature engineering (todas as fontes)**			X	x	x		

8. **Treinamento e validação dos modelos preditivos (RL + Boosting)**				X	x		
9. **Modelo de sobrevivência de Cox (timing)**				X	x		
10. **Segmentação K-means (clusters A-E)**				X	x		
11. **Fine-tuning BERTimbau (sentimento, intenção, NER)**				X	x		
12. **PSM e Uplift Modeling (CATE individual)**					X	x	
13. **Cálculo do LTV discente e Score Composto de Risco (SCR)**					X	x	
14. **Desenvolvimento do protótipo do dashboard**			X	X	X	x	
15. **Validação gerencial com equipe da IES-piloto**						x	x
16. **Redação final do TCC e artigo científico**		X	X	x	x	x	x
17. **Defesa do TCC**							x

x = atividade em execução no período. Defesa prevista para agosto de 2026.

8 CONSIDERAÇÕES PRELIMINARES

O projeto não é apenas um modelo de predição: é um instrumento de gestão orientado por evidências para um setor que, apesar de sua escala e relevância socioeconômica, ainda opera predominantemente com base em intuição e reação tardia. O problema endereçado, inadimplência e evasão em IES privadas, é simultaneamente um desafio de gestão financeira, de marketing de relacionamento, de gestão acadêmica e de política social de acesso à educação superior. Os dados do INEP (2025) e do SEMESP/Principia (2025) confirmam a urgência: com 10 milhões de matrículas, 79,8% na rede privada, evasão de 17,5% no período 2023-2024 (o maior índice desde 2010) e inadimplência de 8,73% no primeiro semestre de 2025, ainda superior a todos os demais setores da economia, o setor acumula perdas financeiras e sociais que nenhuma gestão reativa é capaz de conter.

O referencial teórico e o levantamento de mercado confirmam que o projeto avança sobre o estado da arte em três dimensões simultâneas: a integração inédita de sete fontes de dados em um único pipeline com conformidade LGPD nativa; a

aplicação combinada de técnicas de ponta em um contexto que cada técnica isolada não consegue resolver; e a tradução dos escores preditivos em prescrições gerenciais acionáveis diferenciadas por área funcional, com priorização pelo valor econômico do aluno.

Em seu estágio atual, o projeto conta com a integração concluída com o Moodle (em validação), dados históricos do ERP Prime disponíveis e o ERP Sponte em fase de integração via API. Os demais componentes, WhatsApp, Instagram, Prover e dados externos, estão em fase de ETL. O cronograma prevê a entrega do protótipo funcional e a defesa do trabalho em agosto de 2026. As limitações atuais, restrição a uma única IES-piloto e resultados ainda em construção, são constitutivas da natureza de projeto de pesquisa aplicada e definem a agenda de validação e expansão multi-IES.

A contribuição científica e prática do projeto está, em síntese, em fechar o círculo que a literatura de 50 anos deixou aberto: transformar os dados que as IES privadas já possuem, mas não exploram de forma integrada, em inteligência decisória que preserve o acesso do estudante à educação e a sustentabilidade financeira da instituição.

REFERÊNCIAS

ANDRADE, C. et al. A inadimplência no ensino superior: fatores e soluções. Revista de Ciências da Administração, v. 10, n. 22, p. 88-109, 2008.

ARAÚJO, E. A.; CARMONA, C. U. M. Desenvolvimento de modelos credit scoring com abordagem de regressão logística. Contabilidade Vista & Revista, Belo Horizonte, v. 18, n. 3, p. 107-131, 2007.

ATHEY, S.; KELEHER, N.; SPIESS, J. Machine learning who to nudge: causal vs predictive targeting in a field experiment on student financial aid renewal. Journal of Econometrics, v. 249, 2025. doi: 10.1016/j.jeconom.2024.105945.

BEAN, J. P. Dropouts and turnover: the synthesis and test of a causal model of student attrition. Research in Higher Education, v. 12, n. 2, p. 155-187, 1980.

BEAN, J. P.; METZNER, B. S. A conceptual model of nontraditional undergraduate student attrition. Review of Educational Research, v. 55, n. 4, p. 485-540, 1985.

BRAZIL JOURNAL. Principia levanta R$ 80 milhões para turbinar IA que reduz inadimplência. 2025. Disponível em: https://braziljournal.com. Acesso em: abr. 2026.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD, p. 785-794, 2016.

COX, D. R. Regression models and life-tables. Journal of the Royal Statistical Society, Series B, v. 34, n. 2, p. 187-220, 1972.

DEVLIN, J. et al. BERT: pre-training of deep bidirectional transformers for language understanding. Proceedings of NAACL-HLT 2019, p. 4171-4186, 2019.

DWYER, F. R. Customer lifetime valuation to support marketing decision making. Journal of Direct Marketing, v. 3, n. 4, p. 8-15, 1989.

GRAMBSCH, P. M.; THERNEAU, T. M. Proportional hazards tests and diagnostics based on weighted residuals. Biometrika, v. 81, n. 3, p. 515-526, 1994.

HE, H. et al. ADASYN: adaptive synthetic sampling approach for imbalanced learning. Proceedings of the IEEE IJCNN, p. 1322-1328, 2008.

HERLING, L. H. D. et al. A inadimplência nas IES: um estudo de caso. Revista GUAL, Florianópolis, v. 6, n. 2, p. 126-142, 2013.

HOSMER, D. W.; LEMESHOW, S. Applied Logistic Regression. 2. ed. New York: Wiley, 2000.

INEP — Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Censo da Educação Superior 2024. Brasília: MEC/INEP, 2025. Disponível em: https://www.gov.br/inep. Acesso em: abr. 2026.

JOLLIFFE, I. T. Principal Component Analysis. 2. ed. New York: Springer, 2002.

KE, G. et al. LightGBM: a highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems (NIPS), p. 3146-3154, 2017.

KUMAR, V. Customer Lifetime Value: the path to profitability. Hanover: Now Publishers, 2018.

KÜNZEL, S. R. et al. Metalearners for estimating heterogeneous treatment effects using machine learning. Proceedings of the National Academy of Sciences, v. 116, n. 10, p. 4156-4165, 2019.

LGPD — Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais. Brasília: Presidência da República, 2018.

LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation forest. Proceedings of the 8th IEEE ICDM, p. 413-422, 2008.

LUNDBERG, S. M.; LEE, S. I. A unified approach to interpreting model predictions. Advances in NIPS, p. 4765-4774, 2017.

MACFADYEN, L. P.; DAWSON, S. Mining LMS data to develop an early warning system for educators: a proof of concept. Computers & Education, v. 54, n. 2, p. 588-599, 2010.

MACQUEEN, J. Some methods for classification and analysis of multivariate observations. Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability, p. 281-297, 1967.

MARCOLINO, M. R. et al. Student dropout prediction through machine learning optimization: insights from Moodle log data. Scientific Reports, v. 15, n. 9840, 2025. doi: 10.1038/s41598-025-93918-1.

NAGY, M.; MOLONTAY, R. Interpretable dropout prediction: towards XAI-based personalized intervention. International Journal of Artificial Intelligence in Education, v. 34, p. 274-300, 2024.

PEPPERS, D.; ROGERS, M. Managing Customer Relationships: a strategic framework. 2. ed. New York: Wiley, 2011.

PEREIRA, F. C. C. Modelos preditivos para evasão de alunos no ensino superior privado. 2017. Dissertação (Mestrado em Administração de Empresas) — Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, 2017.

PROKHORENKOVA, L. et al. CatBoost: unbiased boosting with categorical features. Advances in NIPS, p. 6638-6648, 2018.

PROVOST, F.; FAWCETT, T. Data Science for Business: what you need to know about data mining and data-analytic thinking. Sebastopol: O'Reilly Media, 2013.

QUIMIZ-MOREIRA, E. et al. Factors, prediction, explainability, and simulating university dropout through machine learning: a systematic review, 2012-2024. MDPI Computation, v. 13, n. 8, p. 198, 2025. doi: 10.3390/computation13080198.

RABELO, C.; ZÁRATE, L. E. Ensemble-based machine learning for predicting academic dropout in higher education. Data Science and Management, v. 8, n. 1, 2025. doi: 10.1016/j.dsm.2024.07.001.

ROMERO, S.; LIAO, X. Statistical and machine learning models for predicting university dropout and scholarship impact. PLOS ONE, v. 20, n. 6, e0325047, 2025. doi: 10.1371/journal.pone.0325047.

ROSENBAUM, P. R.; RUBIN, D. B. The central role of the propensity score in observational studies for causal effects. Biometrika, v. 70, n. 1, p. 41-55, 1983.

ROSENBERG, E.; GLEIT, A. Quantitative methods in credit management: a survey. Operations Research, v. 42, n. 4, p. 589-613, 1994.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, v. 20, p. 53-65, 1987.

SAADIA, G. N. et al. Machine learning na previsão do risco de inadimplência de alunos do ensino superior. In: XLVI EnANPAD, 2022, Lisboa. Anais... São Paulo: ANPAD, 2022.

SEMESP/PRINCIPIA — Sindicato das Entidades Mantenedoras de Estabelecimentos de Ensino Superior no Estado de São Paulo; Principia. 17ª Pesquisa de Inadimplência no Ensino Superior Privado. São Paulo: SEMESP/Principia, 2025. Disponível em: https://www.semesp.org.br. Acesso em: abr. 2026.

SEMESP. Mapa do Ensino Superior no Brasil 2024. 15. ed. São Paulo: SEMESP, 2025.

SIEMENS, G. Learning analytics: the emergence of a discipline. American Behavioral Scientist, v. 57, n. 10, p. 1380-1400, 2013.

SIEMENS, G.; BAKER, R. S. J. d. Learning analytics and educational data mining: towards communication and collaboration. Proceedings of the 2nd International Conference on Learning Analytics and Knowledge (LAK 2012), p. 252-254, 2012.

SILVA FILHO, R. L. L. et al. A evasão do ensino superior brasileiro. Cadernos de Pesquisa, São Paulo, v. 37, n. 132, p. 641-659, 2007.

SOBRINHO, S. V. Análise da inadimplência em uma escola particular de nível fundamental: uma aplicação de credit scoring. 2007. Dissertação (Mestrado em Administração) — Universidade Federal de Pernambuco, Recife, 2007.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: BRACIS 2020, Lecture Notes in Artificial Intelligence, v. 12319, p. 403-417, 2020.

STARTUPS.COM.BR. Após aporte, Yolo Bank evolui tecnologia e mira crescimento. 2024. Disponível em: https://startups.com.br. Acesso em: abr. 2026.

THOMAS, L. C. A survey of credit and behavioural scoring: forecasting financial risk of lending to consumers. International Journal of Forecasting, v. 16, n. 2, p. 149-172, 2000.

TIUKHOVA, E. et al. Explainable learning analytics: assessing the stability of student success prediction models. Decision Support Systems, v. 182, 2024.

TINTO, V. Dropout from higher education: a theoretical synthesis of recent research. Review of Educational Research, v. 45, n. 1, p. 89-125, 1975.

TINTO, V. Leaving College: rethinking the causes and cures of student attrition. 2. ed. Chicago: University of Chicago Press, 1993.

VAN BUUREN, S.; GROOTHUIS-OUDSHOORN, K. mice: multivariate imputation by chained equations in R. Journal of Statistical Software, v. 45, n. 3, p. 1-67, 2011.

VASWANI, A. et al. Attention is all you need. Advances in NIPS, v. 30, p. 5998-6008, 2017.

VILLAR, A.; DE ANDRADE, C. R. V. Supervised machine learning algorithms for predicting student dropout and failure in higher education institutions. Discover Artificial Intelligence, v. 4, n. 2, 2024. doi: 10.1007/s44163-023-00079-z.

WANG, F.; MOUSAVI, A. Investigating the effect of student-centered learning approaches on academic performance: a longitudinal study. Journal of Learning Analytics, v. 9, n. 1, p. 49-66, 2022.

WIRTH, R.; HIPP, J. CRISP-DM: towards a standard process model for data mining. Proceedings of the 4th International Conference on the Practical Application of Knowledge Discovery and Data Mining, p. 29-39, 2000.